

目录

1	引言	1
2	相关工作	2
2.1	大模型与多模态推理服务	2
2.2	分离式推理	2
2.3	扩散模型并行推理	3
2.4	异构部署	3
2.5	推理缓存技术	3
3	系统设计	4
3.1	系统整体架构	4
3.2	Stage 分离与异构部署	4
3.2.1	Stage 分离设计	4
3.2.2	异构硬件亲和性匹配	4
3.2.3	设备拓扑	4
3.3	跨硬件流水线调度	4
3.3.1	任务队列管理	4
3.3.2	动态批处理策略	4
3.3.3	异步流水线调度	4
3.4	分层启动缓存	4
3.4.1	三级缓存结构	4
3.4.2	缓存预加载与淘汰策略	5
3.5	结果聚合模块	5
4	实验评估	5
4.1	实验设置	5
5	结论	5

一种基于 STAGE 分离和异构部署的多模态推理优化系统

高忠山、凌超凡、黎恩彤、曾立

【摘要】

-

【关键词】

-

1 引言

多模态大模型在文生图（Text-to-Image, T2I）领域的规模化应用对推理系统提出了高并发、低延迟的严峻挑战。当前主流的多模态文生图模型如 Qwen-Image^[1]采用 VAE 编码器-大语言模型特征编码-MMDiT 扩散去噪-VAE 解码器的复合架构，推理流程涉及参数规模、计算特征迥异的多个环节。然而，现有推理服务系统如 vLLM-Omni^[2]虽已实现对自回归多模态模型的 stage 分离推理，但普遍未实现 stage 深度分离与异构硬件精准匹配，存在显著技术缺陷，无法满足高并发、低延迟的规模化推理需求。由此导致三大核心问题：（1）异构硬件资源利用率低，不同算力等级的 AI 处理器与 CPU 间协同效率低下；（2）推理各阶段耦合度高，资源争抢严重，端到端延迟难以控制；（3）大模型权重加载耗时过长，冷启动延迟无法满足高频推理服务需求。

针对上述问题，本文提出一种基于 stage 分离和异构部署的多模态推理优化系统。主要贡献如下：

1. 首次将 DiT 文生图推理 pipeline 拆分为 VAE Encoder、LLM 特征编码、MMDiT Diffusion 生成、VAE Decoder 四个功能独立、边界清晰的 stage，并针对昇腾 NPU 多型号（310P/910C/910B 等）+ CPU 的异构硬件环境，建立基于算力特征、参数规模、耗时占比的硬件亲和性匹配规则，实现各 stage 与异构硬件的精准适配。

2. 设计跨硬件异步流水线调度机制，为每个 stage 维护专属任务队列并结合动态批处理策略，消除阶段间同步等待，显著提升异构硬件并行效率与推理吞吐量。
3. 构建适配 stage 分离架构的三级分层缓存（模型权重缓存、中间特征缓存、推理参数缓存），实现阶段级缓存预加载与淘汰更新，大幅缩短模型冷启动时间。

2 相关工作

2.1 大模型与多模态推理服务

以大语言模型（LLM）高效推理服务为核心，vLLM^[3]提出 PagedAttention 机制实现 KV-cache 内存近零浪费管理，显著提升 LLM 推理吞吐量。SARATHI^[4]通过 chunked-prefill 与 decode-maximal batching 策略，将计算密集的 prefill 与内存密集的 decode 阶段统一调度，有效消除流水线气泡。在多模态服务方向，vLLM-Omni^[2]提出面向 Any-to-Any 多模态模型的完全分离式服务架构。对 Thinker-Talker（如 Qwen2.5-Omni, Qwen3-Omni 等）、AR+DiT（如 GLM-Image 等），AR+ 专用生成器（如 BAGEL 等），通过 stage 级别抽象实现跨模态组件的独立调度与资源分配。

2.2 分离式推理

分离式推理（Disaggregated Inference）将 LLM 推理的 prefill（计算密集）与 decode（内存密集）两阶段拆分至不同硬件，实现独立资源分配与并行度优化。Splitwise^[5]率先论证了 prefill/decode 阶段分离的经济性与可行性，通过将两个阶段部署至不同 GPU 集群实现 1.4 倍吞吐提升与 20% 成本降低。DistServe^[6]进一步将分离策略与 SLO 约束协同优化，消除 prefill-decode 干扰。TetriInfer^[7]提出两级调度 + 资源预测的分离式架构，降低混合负载下的推理干扰。现有分离式推理工作对 DiT 文生图流水线（VAE→文本编码→扩散去噪→VAE 解码）多阶段分离的异构推理部署涉及较少。本工作将异构分离式推理范式拓展至扩散模型领域，提出面向文生图流水线的四阶段深度分离方案。

2.3 扩散模型并行推理

扩散模型的高分辨率图像生成面临巨大计算开销。DistriFusion^[8]提出 *displaced patch parallelism*，利用相邻扩散步骤特征图的高相似性，通过复用前序步骤的 *stale feature map* 实现通信与计算异步重叠，在 8 张 A100 上实现最高 6.1 倍加速。PipeFusion^[9]设计 *patch* 级流水线并行策略，将 DiT 模型层与图像 *patch* 分配至多 GPU，复用一步 *stale* 特征降低通信开销，配合参数分布存储提升内存效率。xDiT^[10]整合序列并行、PipeFusion 流水线并行与 CFG 并行，构建可灵活组合的混合并行推理引擎，首次在以太网互联 GPU 集群上展示 DiT 可扩展性。上述工作聚焦于同构 GPU 环境下的 DiT 模型内部并行加速，未覆盖完整文生图 *pipeline*（含 VAE、文本编码器）的跨阶段异构部署。本工作将并行优化的视野从单一 DiT 模型扩展至端到端文生图全流程。

2.4 异构部署

异构计算环境下 CPU 与 GPU/加速器的协同部署是降低推理成本的重要路径。HeteGen^[11]提出 CPU+GPU 异构张量并行框架，通过异步重叠通信与计算缓解 I/O 瓶颈，实现资源受限设备上的高效 LLM 推理。SiPipe^[12]利用未充分利用的 CPU 资源卸载辅助计算与通信任务，通过 CPU *sampling*、*token-safe* 执行模型与结构感知传输三项技术缓解流水线气泡，在多 GPU 流水线并行部署中提升 GPU 利用率达 23%。Hybrid SD^[13]将 Stable Diffusion 的早期扩散步骤部署于云端大模型实现语义规划，后期步骤部署于边缘端小模型完成视觉细节精炼，实现边缘-云协同扩散推理。现有异构部署方案止于 CPU-GPU/云端-边缘的二元划分，尚未针对昇腾 NPU 多型号（310P/910C/910B 等）的算力梯度差异做逐 *stage* 的硬件亲和性精准匹配。本工作首次提出面向四级异构硬件的 *stage*-硬件亲和性匹配方法。

2.5 推理缓存技术

缓存技术是缩短模型启动延迟、提升推理效率的关键手段。LMCache^[14]提出层次化 KV 缓存方案，支持 GPU 显存 ↔ CPU 内存 ↔ 磁盘 ↔ 远程存储的多层级缓存迁移与跨引擎复用，在 *prefix caching* 场景实现最高 15 倍吞吐提升。IMPRESS^[15]构建基于重要性的多级前缀 KV 存储系统，根据访问频率动态调整缓存层级，实现高命中率下的存储成本优化。PRESERVE 通过模型

权重与 KV Cache 的预取实现通信与计算重叠，缩短冷启动延迟。现有缓存方案几乎全部聚焦于 KV-cache 的层次化管理与跨请求复用，尚未出现适配 stage 分离架构的模型权重 + 中间特征 + 推理参数三级缓存设计。本工作提出了与四阶段分离推理深度耦合的三级分层缓存机制，填补了这一空白。

3 系统设计

3.1 系统整体架构

本系统由四个核心模块组成：**stage** 异构部署模块、跨硬件流水线调度模块、分层启动缓存模块、结果聚合模块。各模块数据互通、协同工作，形成闭环式推理优化架构。

3.2 Stage 分离与异构部署

3.2.1 Stage 分离设计

3.2.2 异构硬件亲和性匹配

3.2.3 设备拓扑

3.3 跨硬件流水线调度

3.3.1 任务队列管理

3.3.2 动态批处理策略

3.3.3 异步流水线调度

3.4 分层启动缓存

3.4.1 三级缓存结构

构建与 **stage** 分离架构深度适配的三级分层缓存：

1. 模型权重缓存：缓存各 **stage** 对应的模型主干权重（例如 MMDiT 约 20GB），按 **stage** 粒度独立管理，支持 **stage** 级精准加载与卸载。
2. 中间特征缓存：缓存常用风格的中间层特征表示（例如 500+ 种风格特征），支持跨请求复用，减少重复编码开销。

3. 推理参数缓存：缓存推理运行时参数（采样参数、CFG scale、随机种子等），加速推理任务快速启停。

3.4.2 缓存预加载与淘汰策略

-

3.5 结果聚合模块

-

4 实验评估

4.1 实验设置

硬件环境 CPU: Kunpeng-920; 昇腾 NPU-310P (显存 24GB); 昇腾 NPU-910C (显存 64GB); 昇腾 NPU-910B (显存 32GB)。

5 结论

-

参考文献

- [1] WU C, LI J, ZHOU J, et al. Qwen-Image Technical Report[EB/OL]. arXiv. 2025 [2026-04-27]. <http://arxiv.org/abs/2508.02324>.
- [2] YIN P, ZHU J, GAO H, et al. vLLM-Omni: Fully Disaggregated Serving for Any-to-Any Multimodal Models[EB/OL]. arXiv. 2026 [2026-04-27]. <http://arxiv.org/abs/2602.02204>.
- [3] KWON W, LI Z, ZHUANG S, et al. Efficient Memory Management for Large Language Model Serving with PagedAttention[EB/OL]. arXiv. 2023 [2026-04-27]. <http://arxiv.org/abs/2309.06180>.

- [4] AGRAWAL A, PANWAR A, MOHAN J, et al. SARATHI: Efficient LLM Inference by Piggybacking Decodes with Chunked Prefills[EB/OL]. arXiv. 2023 [2026-04-27]. <http://arxiv.org/abs/2308.16369>.
- [5] PATEL P, CHOUKSE E, ZHANG C, et al. Splitwise: Efficient generative LLM inference using phase splitting[EB/OL]. arXiv. 2024 [2026-04-27]. <http://arxiv.org/abs/2311.18677>.
- [6] ZHONG Y, LIU S, CHEN J, et al. DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving[EB/OL]. arXiv. 2024 [2026-04-27]. <http://arxiv.org/abs/2401.09670>.
- [7] HU C, HUANG H, XU L, et al. Inference without Interference: Disaggregate LLM Inference for Mixed Downstream Workloads[EB/OL]. arXiv. 2024 [2026-04-27]. <http://arxiv.org/abs/2401.11181>.
- [8] LI M, CAI T, CAO J, et al. DistriFusion: Distributed Parallel Inference for High-Resolution Diffusion Models[EB/OL]. arXiv. 2024 [2026-04-27]. <http://arxiv.org/abs/2402.19481>.
- [9] FANG J, PAN J, LI A, et al. PipeFusion: Patch-level Pipeline Parallelism for Diffusion Transformers Inference[EB/OL]. arXiv. 2025 [2026-04-27]. <http://arxiv.org/abs/2405.14430>.
- [10] FANG J, PAN J, SUN X, et al. xDiT: an Inference Engine for Diffusion Transformers (DiTs) with Massive Parallelism[EB/OL]. arXiv. 2024 [2026-04-27]. <http://arxiv.org/abs/2411.01738>.
- [11] ZHAO X, JIA B, ZHOU H, et al. HeteGen: Heterogeneous Parallel Inference for Large Language Models on Resource-Constrained Devices[EB/OL]. arXiv. 2024 [2026-04-27]. <http://arxiv.org/abs/2403.01164>.
- [12] HE Y, ZHAO B, CAO Z. SiPipe: Bridging the CPU-GPU Utilization Gap for Efficient Pipeline-Parallel LLM Inference[EB/OL]. arXiv. 2025 [2026-04-27]. <http://arxiv.org/abs/2506.22033>.
- [13] YAN C, LIU S, LIU H, et al. Hybrid SD: Edge-Cloud Collaborative Inference for Stable Diffusion Models[EB/OL]. arXiv. 2024 [2026-04-27]. <http://arxiv.org/abs/2408.06646>.
- [14] LIU Y, CHENG Y, YAO J, et al. LMCache: An Efficient KV Cache Layer

for Enterprise-Scale LLM Inference[EB/OL]. arXiv. 2025 [2026-04-27]. <http://arxiv.org/abs/2510.09665>.

- [15] CHEN W, HE S, QU H, et al. IMPRESS: An Importance-Informed Multi-Tier Prefix KV Storage System for Large Language Model Inference[C]//. 2025: 187-201.